

XGBoost를 활용한 제주 전력시장 하루 전(Day-Ahead) 전기가격 예측

김 진¹

¹부산대학교 의생명융합공학부

202255644@pusan.ac.kr

Day-Ahead Electricity Price Prediction in Jeju Power Market Using XGBoost

Jin Kim¹

요약

본 보고서는 제주 전력시장의 하루 전(Day-Ahead) 전기가격(SMP) 예측을 목표로 한 대회 참여 과정과 그 결과를 다룬다. 재생에너지 도입으로 인해 전기가격의 변동성이 증가함에 따라, 이를 효과적으로 예측하기 위해 2024년 3월부터 10월까지 제공된 데이터를 활용하여 탐색적 데이터 분석(EDA)과 전처리를 수행하였다. 주요 변수로 기상 데이터, 시간대별 특성을 반영하여 XGBoost 모델을 구축하였다. 모델은 양수 가격 구간에서 높은 성능을 보였으나, 음수 가격 구간이나 극단적 변동 구간에서는 상대적으로 낮은 예측 정확도를 나타냈다. 대회에서 약 200개 팀 중 17위를 기록하며 참가상을 수상하였고, 이를 통해 시계열 데이터를 효과적으로 분석하고 예측 모델을 설계하는 데 필요한 실질적인 경험과 통찰을 얻을 수 있었다.

1. 서론

재생에너지의 도입이 확대됨에 따라 전력시장에서 전기가격을 정확히 예측하는 작업은 점차 어려워지고 있으나, 그 중요성은 더욱 강조되고 있다. 특히, 재생에너지 비중이 높은 제주 전력시장은 기존 전력시장에 비해 전기가격 변동성이 크며, 이를 효과적으로 관리하는 것은 안정적인 시장 운영과 재생에너지 확대를 위한 필수적인 과제로 여겨진다.

본 보고서는 제주 전력시장의 하루 전(Day-Ahead) 전기가격(SMP)을 예측하기 위한 경진대회 참여 과정과 그 결과를 다루고자 한다. 2024년 3월부터 10월까지 제공된 정적 데이터와 실시간 API 데이터를 활용하여 탐색적 데이터 분석(EDA)을 수행하고, 머신러닝 기법을 적용하여 예측 모델을 개발하였다.

예측에는 높은 성능과 유연성을 갖춘 Gradient Boosting 알고리즘인 XGBoost를 사용하였으며, 음수 전기가격 구간을 포함한 다양한 가격 조건에서 높은 예측 정확도를 목표로 하였다. 이를 통해 전력시장 데이터 분석의 가능성을 탐구하고, 주요 과제와 개선 방안을 논의하고자 한다.

2. 데이터 개요

본 대회에서는 제주 전력시장 경진대회에서 제공된 데이터를 활용하여 하루 전(Day-Ahead) 전기가격(SMP)을 예측하였다. 데이터는 다양한 시간 간격과 변수로 구성되어 있으며, 주요 내용은 다음과 같다.

2.1 제공 데이터셋

하루 전 시장 SMP : 1시간 단위로 제공된 전기가격 데이터

실시간 시장 SMP : 15분 단위로 제공된 임시 및 확정 전기가격 데이터

전력시장 현황 : 5분 단위로 측정된 전력시장 주요 지표

기상 데이터 : 제주 지역 별 기상 실측 및 예보 데이터

2.2 데이터 특징

데이터셋은 2024년 3월 1일부터 2024년 10월 21일까지를 포함한다. 각 데이터셋마다 시간 단위가 다르므로 분석 및 모델링의 일관성을 위해 데이터 정렬 및 통합이 필요하다.

3. 데이터 탐색 및 정제

3.1 데이터 탐색(EDA)

3.1.1 하루 전 SMP 데이터의 주기성

하루 전 SMP 데이터를 월별로 시각화 한 결과, 월마다 다른 주기적인 패턴이 나타나는 것을 확인 할 수 있었다. 이러한 주기적 패턴은 계절 요인과 전력 수요의 변화가 SMP에 영향을 미친다는 점을 시사하며, 이를 모델링 과정에서 반영할 필요가 있다.




그림 1. 월별 하루 전 SMP

3.1.2 하루 전 SMP 데이터의 극단적 변동 탐지

하루 전 SMP 데이터를 전체적으로 시각화한 결과, 일부 시간대에서 SMP 가격이 극단적으로 떨어지거나, 매우 높은 값을 가지는 구간이 존재하였다. 이러한 극단적 변동은 전력시장의 특수성을 반영하며, 단순 이상치로 제거하기 보다는 모델 학습에서 중요한 학습요소로 활용해야 한다. 다만, 이러한 극단치가 모델 학습 과정에서 잘못 처리될 경우, 모델의 성능에 부정적인 영향을 미칠 수 있다는 점에 주의해야 한다. 극단적인 값이 과도하게 강조되면, 모델이 데이터의 일반적인 패턴을 학습하기보다는 극단치에 과적합(overfitting)될 위험이 있다. 예를 들어, 모델이 음수 가격이나 급격히 높은 가격 변동 구간에 지나치게 민감하게 반응하도록 학습될 경우, 일반적인 구간에서의 예측 정확도가 저하될 수 있다.




그림 2. 하루 전 SMP 데이터

3.1.3 수요와 공급의 관계 분석

전력시장에서 SMP는 일반적으로 수요와 공급의 상호작용에 의해 결정될 것으로 예상되었으나, 이를 확인하기 위해 수요, 공급 데이터와 SMP 간의 상관관계를 분석한 결과, 두 변수와 SMP 간의 직접적인 상관관계는 크지 않은 것으로 나타났다. 대신 SMP는 시간대와 날씨와 같은 다른 요인에 더 큰 영향을 받는 것으로 분석되었다. 이는 수요와 공급만으로 SMP를 예측하기에는 한계가 있음을 시사한다. 이러한 결과는 SMP의 변동성을 정확히 이해하고 예측하기 위해서는 수요와 공급 외에도 시간대, 재생에너지 발전량 등의 요인을 통합적으로 고려해야 함을 보여준다.

3.2 데이터 전처리(Preprocessing)

3.2.1 스케일링

데이터 정제 과정에서는 먼저 데이터의 값 범위를 정규화 하기 위해 Min-Max Scaler를 사용하였다. 이를 통해 데이터의 각 값이 동일한 범위로 조정되었으며, 모델 학습 과정에서 특정 값이 지나치게 큰 영향을 미치지 않도록 처리하였다.

정규화 과정은 특히 전력시장 데이터의 다양한 변동성을 학습하는 데 유리하며, 이는 모델 성능의 안정성을 높이는 데 중요한 역할을 한다. 정규화 후 데이터 분포를 재검토하여, 스케일링이 데이터의 본질적인 패턴이나 관계에 영향을 미치지 않았음을 확인하였다. 이를 통해 모델 학습의 기반을 강화하고, 과적합(overfitting) 위험을 줄일 수 있었다.

3.2.2 시간 단위 조정

데이터셋 간의 시간 단위가 상이했기 때문에 이를 1시간 단위로 통합하는 과정을 수행하였다. 날씨 데이터는 5분 간격으로 제공되었으므로, 각 1시간 단위로 평균값을 계산하여 통합하였다. 실시간 시장 확정 SMP 데이터는 15분 간격으로 제공되었으며, 마찬가지로 1시간 단위로 평균값을 계산하여 일관된 시간 단위로 조정하였다. 이러한 시간 단위 조정 작업을 통해 데이터셋 간의 일관성을 확보하였으며, 이를 기반으로 모델 학습에 적합한 형태로 변환할 수 있었다.

3.2.3 파생 변수 생성

파생 변수 생성 과정에서는 모델이 SMP 데이터를 효과적으로 학습할 수 있도록 시간적 특성과 시계열 정보를 반영하는 다양한 변수를 추가하였다. 먼저, 시간대 정보를 모델이 학습할 수 있도록 시간 데이터를 삼각함수($\sin-\cos$)로 변환하여 주기성을 반영하였다. 예를 들어, 하루 주기를 나타내기 위해 $\sin(2\pi * \text{시간}/24)$ 와 $\cos(2\pi * \text{시간}/24)$ 를 생성하여 시간대별 변화를 모델이 학습할 수 있도록 구성하였다.

또한, 월별 주기성을 반영하기 위해 월 데이터를 동일한 방식으로 변환하여 계절적 특성을 변수에 포함하였다. 예를 들어, $\sin(2\pi * \text{월}/12)$ 와 $\cos(2\pi * \text{월}/12)$ 를 사용하여 계절별 변동성을 학습에 반영하였다.

시계열 데이터의 의존성을 모델이 학습할 수 있도록 과거 SMP 데이터를 활용하여 1~3일 전 동일 시간대의 SMP 가격을 새로운 변수로 추가하였다. 이는 과거의 SMP 변동이 현재 가격에 미칠 영향을 모델이 학습하는 데 도움을 준다. 이와 더불어, 동일 시간대의 SMP 가격 평균값과 표준편차를 계산하여 시간대별 일반적인 경향과 변동성을 반영하는 변수를 생성하였다. 이를 통해 특정 시간대의 가격 변동 패턴을 모델이 보다 잘 이해할 수 있도록 하였다.

마지막으로, 전력 수요와 SMP 가격이 주말과 평일에 따라 다른 양상을 보일 가능성을 반영하기 위해 주말 여부를 나타내는 더미 변수(0, 1)를 생성하였다. 이 변수는 전력 수요와 공급이 주말과 평일에 따라 달라지는 구조를 모델이 학습하는 데 기여한다.

이와 같은 다양한 파생 변수는 SMP 데이터의 시간적, 계절적, 시계열적 특성을 반영하며, 모델이 데이터를 보다 정교하게 학습할 수 있도록 설계되었다.

4. 모델링 접근법

4.1 모델 선정

예측 모델로는 XGBoost 회귀 모델을 사용하였다. XGBoost는 과거 유사한 시계열 예측 대회에서 우수한 성능을 보인 사례가 많아 선택되었다. 특히, 시계열 데이터에서 강점을 보이는 특성상 결측값 처리 및 Feature Importance 제공 등 모델의 해석 가능성이 장점으로 작용하였다. LSTM과 같은 딥러닝 기반의 시계열 모델도 실험적으로 사용해 보았으나, 데이터 크기가 충분하지 않았던 것으로 예상되며 학습 결과가 XGBoost보다 저조하였다. 이러한 결과를 바탕으로, 상대적으로 데이터 요구량이 적고 성능이 안정적인 XGBoost를 최종 모델로 선정하였다.

4.2 데이터 분할

시계열 데이터의 특성을 반영하기 위해 데이터를 시간 순서에 따라 분할하였다. 전체 데이터의 앞쪽 80%를 훈련 데이터로, 뒤쪽 20%를 검증 데이터로 사용하였다. 이를 통해 학습 과정에서 미래 데이터를 학습하지 않도록 방지하고, 검증 데이터로 현실적인 예측 성능을 평가할 수 있도록 구성

하였다.




그림 3. 데이터 분할

4.3 특성 선택(Feature Selection)

모델 입력 변수는 XGBoost를 이용하여 Feature Importance를 분석한 후 선정하였다. 초기에는 모든 후보 변수를 포함하여 학습을 진행하였으며, 학습 결과 중요도가 미미한 변수들은 제거하여 최종적으로 의미 있는 변수들만 남겼다. 이러한 과정은 데이터의 복잡성을 줄이고, 모델이 중요하지 않은 변수에 학습 자원을 낭비하지 않도록 하기 위함이다.




그림 4. Feature Importance 시각화

4.4 모델 학습 및 하이퍼파라미터 튜닝

모델 학습 과정에서는 하이퍼파라미터 최적화를 위해 Optuna를 사용하였다. Optuna는 효율적인 탐색 알고리즘을 통해 수많은 조합 중에서 최적의 하이퍼파라미터를 찾을 수 있도록 도와준다. 본 실험에서는 Optuna를 활용하여 100,000번의 실험을 수행하며 최적의 하이퍼파라미터를 탐색하였다. 이를 통해 모델의 학습 속도와 성능 간의 균형을 최적화할 수 있었다.

4.5 모델 평가

최종 모델의 예측 결과를 평가한 결과, SMP의 추세를 전반적으로 잘 따라가는 것을 확인할 수 있었다. 다만, 극단적인 이상치 구간에서는 모델이 이를 충분히 따라가지 못하는 한계가 있었다. 이는 데이터의 특성상 이상치가 상대적으로 적어 모델이 이를 학습하기 어려웠기 때문으로 보인다. 이러한 결과는 모델의 성능을 개선하기 위해 극단치에 대한 추가적인 처리나 보강 데이터가 필요함을 시사한다.




그림 5. 실제 SMP(주황색)와 예측 SMP(파란색)

5. 대회결과 및 결론

본 대회에서는 약 200개의 팀이 참가한 가운데 17등이라는 결과를 기록하며 참가상(200,000KRW)을 수상하였다. 결과적으로 상위 10%에 근접한 성과를 이루었으며, 대회 목표였던 제주 전력시장의 하루 전 전기가격 예측에 대한 이해와 모델링 경험을 쌓는 데 성공하였다.




그림 6. 대회 결과

특히, 이번 대회를 통해 시계열 데이터를 다루는 방법과 관련된 다양한 분석 및 모델링 기법을 처음으로 학습하며 흥미로운 경험을 얻을 수 있었다. 시계열 데이터의 주기성과 계절성을 반영하기 위한 방법, 극단적인 변동을 처리하기 위한 전처리, 그리고 하이퍼파라미터 최적화를 통한 모델 성능 개선 등 다양한 과정을 거치며 데이터 분석 및 머신러닝에 대한 이해도를 한층 높일 수 있었다. 또한, 사전학습된 모델 (Pretrained Model)을 사용해 성능을 더욱 향상시키고자 했으나, 파인튜닝(Fine-Tuning)에 대한 충분한 이해와 경험이 부족해 실제 적용하지 못한 점이 아쉬움으로 남았다. 이 점은 향후 학습을 통해 보완할 필요가 있음을 느끼게 해주었다.

예측 모델의 성능은 전체적인 가격 추세를 잘 따라가는 모습을 보였지만, 극단적인 이상치 구간에서는 다소 한계를 드러냈다. 이러한 결과는 데이터를 더욱 심층적으로 분석하고, 극단값 처리에 대한 보완적인 접근이 필요하다는 점을 시사한다.

이번 대회는 단순히 예측 성능에 초점을 맞추는 것을 넘어, 시계열 데이터의 특성을 이해하고 이를 분석과 모델링에 효과적으로 적용하는 방법을 학습할 수 있는 귀중한 기회였다. 앞으로는 이 경험을 바탕으로 더 복잡한 데이터와 문제를 다룰 수 있는 역량을 키우고, 다양한 모델링 기법과 사전학습 모델의 활용을 포함한 고도화된 접근을 실험적으로 적용하며 데이터 분석의 폭을 넓혀나갈 계획이다.

6. 참고문헌

[1] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge

Discovery and Data Mining (KDD '16), 785–794. <https://doi.org/10.1145/2939672.2939785>

[2] Optuna Developers. *Optuna: A Hyperparameter Optimization Framework*. Retrieved from <https://optuna.org/>

[3] Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). *Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting*. International Journal of Forecasting, 37(4), 1742–1757. <https://doi.org/10.1016/j.ijforecast.2021.03.012>

[4] Qingsong Wen, Tian Zhou, Chaoli Zhang, Weiqi Chen, Ziqing Ma, Junchi Yan, Liang Sun (2023). Transformers in Time Series: A Survey. <https://arxiv.org/abs/2202.07125>



그림 7. 대회 포스터